

Détection d'anomalies industrielles

De l'image brute à une décision qualité : détecter une pièce défectueuse et localiser la zone suspecte.

Comprendre les données, préserver le signal utile, puis adapter le modèle au contexte industriel.

Objectifs du projet

Besoin qualité

Décider si une pièce est normale ou défectueuse, avec une heatmap exploitable par un inspecteur.

détection image

localisation pixel

faible faux positif

limiter les non conformités

Livrables data science

EDA, harmonisation, preprocessing, baselines, modèles avancés, métriques, interprétation et démonstrateur Streamlit.

notebooks

GitHub

rapport

démo

Le score global ne suffit pas : une bonne classification image reste insuffisante si la localisation n'est pas utilisable.

Notre boucle expérimentale

1

Tester

Modèle simple ou variante ciblée

2

Évaluer

AUROC, AUPIMO, heatmaps, erreurs

3

Diagnostiquer

Modèle, preprocessing, ROI ou seuil

4

Itérer

Crops, ROI, layers, post-traitement

5

Décider

Conserver, abandonner ou spécialiser

Image AUROC / AP

Décision pièce normale ou défectueuse.

Pixel AUROC / AP







Qualité de localisation de la heatmap.

AUPIMO

Localisation exploitable avec peu de faux positifs.

Notre métrique métier centrale devient l'AUPIMO : localiser juste, sans transformer l'inspection en chasse aux faux positifs.

Partie 1 - EDA : à quoi ressemblent les datasets



EDA : premiers constats mesurés

MVTec AD



Benchmark propre, 15 catégories, masques disponibles, structure standard.

HSS IAD

Dataset plus difficile, pièces métalliques, défauts subtils, forte variabilité visuelle.

Décision

Ne pas lire uniquement une moyenne globale. Les résultats doivent être analysés par catégorie.



Conséquence : pas de preprocessing unique

Géométrie et ROI

- resize contrôlé, éviter le resize agressif 224/256 ;
- center_crop seulement quand il ne coupe pas le défaut ;
- tiling + stride pour les formats extrêmes ;
- variation local / contexte pour garder détail et structure ;
- ROI érodée, foreground mask, ROI métier et landmarks.

Robustesse et apprentissage

- denoising et filtrage qualité quand le fond domine ;
- simulation de défauts pour certaines familles ;
- Masked Modeling et Masked Semantic Inpainting comme pistes ;
- augmentations : rotations, flip, color-jitter, normalisation photométrique ;
- équilibrage et stratification pour évaluer sans moyenne trompeuse.

Le preprocessing définit ce que le modèle a le droit de voir et ce que le score doit ignorer.

Acte 2 - Baselines : diagnostiquer avant d'optimiser

Baseline	Paramètres principaux	Hypothèse	Constat	Décision
Autoencodeur	ConvAE, batch 1, 5 epochs, reconstruction image	Une anomalie doit être mal reconstruite	Signal trop diffus, faible pouvoir discriminant	Baseline historique uniquement
PatchCore	ResNet18 gelé, layers 2 et 3, tuiles 384, overlap 0.50, kNN euclidien	Une zone anormale est éloignée des patches normaux	Plus robuste et plus local	Baseline forte et interprétable

Première leçon : le modèle diagnostique une limite, mais il ne peut pas retrouver un défaut détruit par le preprocessing.

Dinomaly change la donne

Pourquoi ça change

Dinomaly utilise DINOv2 et reconstruit des features normales plutôt que des pixels. Les défauts topologiques et structurels deviennent plus lisibles.

Ce qui reste à adapter

La performance dépend encore du périmètre, de la résolution, des crops, des ROI, du post-traitement et du checkpoint retenu.

Dinomaly améliore nettement MVTec et cable, mais ne résout pas automatiquement STEEL ni Casting.

MVTec : validation benchmark

Avant de conclure sur les cas industriels, on vérifie que le pipeline fonctionne sur un standard reconnu.

- 15 catégories MVTec AD ;
- comparaison Dinomaly, PatchCore et approches complémentaires ;
- normalisation globale par modèle ;
- ensemble Mean : Dinomaly + PatchCore manuel.

0.843


AUPIMO moyen avec Ensemble Mean

Dinomaly seul : 0.763. Référence moderne : environ 0.86.

Réussir MVTec ne suffit pas, mais cela prouve que la chaîne est techniquement crédible.

Cable : notre cas de réussite vérifié

Scénario	Image AUROC	Pixel AUROC	AUPIMO
PatchCore V7	0.762	0.847	0.075
Dinomaly V11	0.960	0.922	0.380
Dinomaly V13 best	0.957	0.927	0.443
Dinomaly final 3cat	0.991	0.923	0.576
Dinomaly final MVTec	0.998	0.976	0.783



Cable montre que le triptyque ROI, preprocessing par catégorie et Dinomaly peut produire une localisation beaucoup plus exploitable que la baseline PatchCore.

STEEL : Dinomaly ne suffit pas

Difficulté

- résolution native 256 x 1600, ratio 1:6.25 ;
- forte variabilité intra-normal : surfaces lisses, striées, masquées ;
- défauts subtils, localisés et peu contrastés ;
- les heatmaps peuvent scorer le bruit sain au lieu du défaut.

Étape	Score clé	Lecture
ConvAE	AUROC image 0.531	reconstruction pixel insuffisante
DINOv2 / PatchCore	AUROC image 0.572	transfert limité
SuperSimpleNet	AUROC pixel 0.760	meilleure localisation
tail_mean	AUROC image 0.638	meilleure agrégation pixel -> image

STEEL est un échec informatif : la difficulté vient autant de l'agrégation et de la variabilité saine que du choix du backbone.

Casting : ROI métier + Reverse Distillation calibré

Pourquoi c'est difficile

- micro-défauts, trous, bords et filetages proches des anomalies ;
- plusieurs patterns de vue dans Casting_class1 ;
- le resizing global dilue les défauts ;
- avant de détecter, il faut apprendre où regarder.

Réponse retenue

- ROI de surface fonctionnelle pour isoler la zone inspectable ;
- séparation ROI d'affichage / ROI de scoring ;
- Reverse Distillation sur features normales ;
- calibration post-hoc : layer2 0.65, layer3 0.35, top-k 0.005.

image AP 0.8461 - pixel AP 0.2251 - AUPIMO 0.0571

Lecture transversale des trois classes

Classe	Preprocessing clé	Modélisation	Résultat / limite
Cable	ROI, érosion, crops adaptés	Dinomaly	réussite nette, AUPIMO final 3cat 0.576
STEEL	tuilage, masque steel, agrégation robuste	SuperSimpleNet + <code>tail_mean</code>	pixel AUROC 0.760, image AUROC 0.638
Casting	ROI métier, landmarks, scoring local	Reverse Distillation calibré	image AP fort, localisation encore limitée

La conclusion scientifique n'est pas “un meilleur modèle pour tout”, mais “une stratégie par catégorie selon géométrie, défauts et usage qualité”.

Ce que nous avons réellement appris

Le modèle compte

PatchCore, PaDiM et Dinomaly ne font pas le même compromis entre texture locale, structure globale et reconstruction de features.

Mais la chaîne compte plus

ROI, crops, résolution utile, seuils, post traitement et choix du checkpoint changent directement la qualité des heatmaps.

La performance utile vient de l'alignement entre données, preprocessing, métrique et usage qualité.

CONCLUSION

Notre épopée en une phrase

Nous sommes partis d'une détection générique d'anomalies, et nous avons construit progressivement une chaîne plus métier : regarder les bonnes zones, comparer les modèles avec les bonnes métriques, puis stabiliser la décision.

Pour détecter correctement un défaut industriel, il ne suffit pas d'avoir un bon modèle : il faut préserver le signal utile et apprendre au pipeline où regarder.

Transition démo : image brute, preprocessing / ROI, modèle, heatmap, score image, masque de référence, décision qualité.